Tarea 1 — Procesamiento Masivo de Datos

Integrantes: Maximiliano Del Rio · Patricio Aylwin

Repositorio: *(pegar link)*.

1. Resumen

Datos y alcance. Procesamiento Masivo de Datos (ELE051-B / EIN102B), USM 2026-2, paralelo 701. OpenStreetMap (Geofabrik `chile-260910`, extracto del 10-sep-2026) · GTFS DTPM `GTFS_20261003` (V168, vigencia 03-oct → 31-dic-2026) · DPA 2023. Todo en SRID 5361; caja lon −70,75…−70,52 · lat −33,52…−33,36 (Santiago centro).

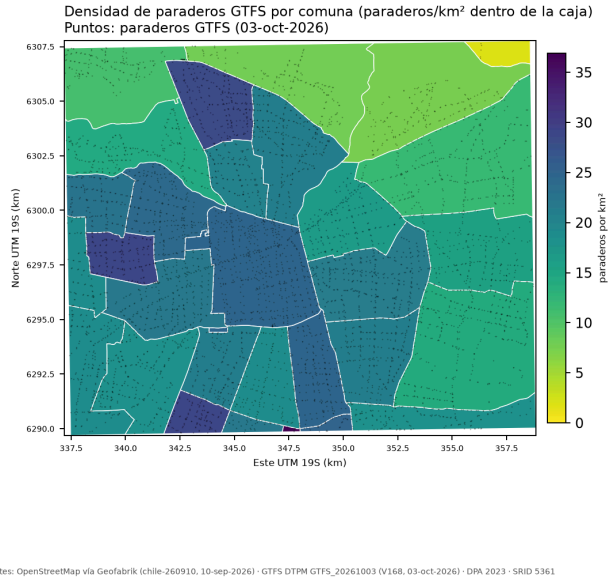
En la caja de Santiago centro hay **118.700 edificios** (OSM) y **6.569 paraderos de bus** en 338 rutas (GTFS). Con la distancia en línea recta, **solo el 1,1 % de los edificios queda a más de 500 m de un paradero GTFS** (1,0 % con los `bus_stop` de OSM): la ciudad construida está casi toda «cubierta» por buses. La relación interesante no es la presencia sino la **intensidad**: la oferta se concentra en un eje poniente–oriente y hay celdas con muchos edificios y pocos recorridos en el oriente. Las dos fuentes de paraderos coinciden en ~94 % a 50 m. Alcance: **solo buses**; el Metro y el tren del feed se excluyeron (ver decisiones), así que las zonas atendidas por Metro aparecen peor servidas de lo que están.

2. Respuestas a las preguntas

2.1 Paraderos GTFS por comuna (punto-en-polígono)

6.569 paraderos en 30 comunas. Densidad = paraderos por km² *de la comuna dentro de la caja*. Mayores: San Ramón 36,9 (6 paraderos en 0,2 km²), Lo Espejo 29,2, Lo Prado 29,2, Conchalí 28,4; Santiago tiene 573 (24,7/km²). Menores: Lo Barnechea 1,8 (5 en 2,8 km²), Vitacura 7,4, Huechuraba 7,9.

> **Interpretación.** Las comunas pericentrales de trama densa (Conchalí, Lo Prado, Lo Espejo) superan al propio centro; el oriente de baja densidad (Vitacura, Huechuraba, Las Condes 11,8) tiene menos de la mitad. San Ramón y Lo Barnechea son comunas casi fuera de la caja: son cifras de borde, no de comuna. *Fuente: GTFS 03-oct-2026.*



Mapa 2. Densidad de paraderos GTFS por comuna (Q1).

2.2 Cobertura a 500 m (anti-join `ST_DWithin`)

Comuna	Edificios	% a >500 m, GTFS	% a >500 m, OSM
Huechuraba	1.269	10,7	10,4
Quilicura	2.279	7,6	7,6
La Florida	953	4,5	4,5
Recoleta	3.086	1,9	1,0
Providencia	12.123	0,7	0,1
Total de la caja	**118.700**	**1,14**	**0,97**

> **Interpretación.** La conclusión de fondo no cambia con la fuente: la brecha está en la periferia norte (Huechuraba, Quilicura) y no en el centro. Donde las fuentes difieren (Recoleta, Providencia) OSM «ve» más paraderos cerca que el GTFS: cualquiera de los dos puede tener un paradero mal ubicado. Ver mapa 3. Medido desde el punto interior del edificio, en línea recta. *Fuentes: OSM 10-sep-2026; GTFS 03-oct-2026.*

Plan (Q2). `EXPLAIN ANALYZE`: *Nested Loop Anti Join*; lado externo `Parallel Seq Scan` de `edificios` (118.700 filas), lado interno **Index Scan con** `idx_paraderos_gtfs_geom` (`Index Cond: geom && st_expand(e.punto, 500)`, luego el filtro exacto `st_dwithin`): 0,75 s. Con los índices deshabilitados, el mismo anti-join compara cada edificio con los 6.569 paraderos (97 millones de pares descartados en total): **31,0 s, ~41 veces más lento**. El índice se usa sobre la tabla pequeña porque es la que se consulta 118.700 veces.

2.3 Dos fuentes, un objeto (anti-join en ambos sentidos)

Umbral	GTFS sin `bus_stop` OSM	`bus_stop` OSM sin GTFS
25 m	1.004 (15 %)	995 (15 %)
50 m	**381 (5,8 %)**	**364 (5,5 %)**
100 m	141 (2,1 %)	137 (2,1 %)

Totales: 6.569 paraderos GTFS y 6.567 `bus_stop` (81 sin nombre).

> **Interpretación.** Las dos fuentes tienen casi el mismo número de paraderos y a 50 m coinciden en ~94 %; el desacuerdo cae de 15 % a 2 % entre 25 y 100 m, así que la mayor parte es **desplazamiento posicional** (acera/costado, nodo vs. plataforma), no paraderos ausentes. Los ~2 % que persisten a 100 m sí son diferencias reales de completitud, en ambos sentidos y de tamaño similar: ninguna fuente es «completa» respecto de la otra. Los de OSM son los que alguien dibujó; los del GTFS, los que el operador declara (V168, 03-oct-2026).

2.4 Kilómetros de recorrido por comuna (`ST_Intersection`, líneas contra polígonos)

Con recorridos canónicos (un shape por ruta y sentido): Santiago 1.099 km (149 rutas), Las Condes 605, Estación Central 517, Peñalolén 450, Ñuñoa 387, Providencia 378. Contando todas las variantes, los km suben 17 % en Santiago y 45 % en Peñalolén (de 450 a 652 km).

Polígonos de comuna usados	Execution Time (varía ~±15 % entre corridas)
`comunas_cl` enteras (país)	1.208 ms
enteras + `ST_Subdivide(256)`	547 ms (×2,2)
`comunas_zona` (recortadas a la caja)	440 ms
recortadas + `ST_Subdivide` (`comunas_sub`)	426 ms (×1,0)

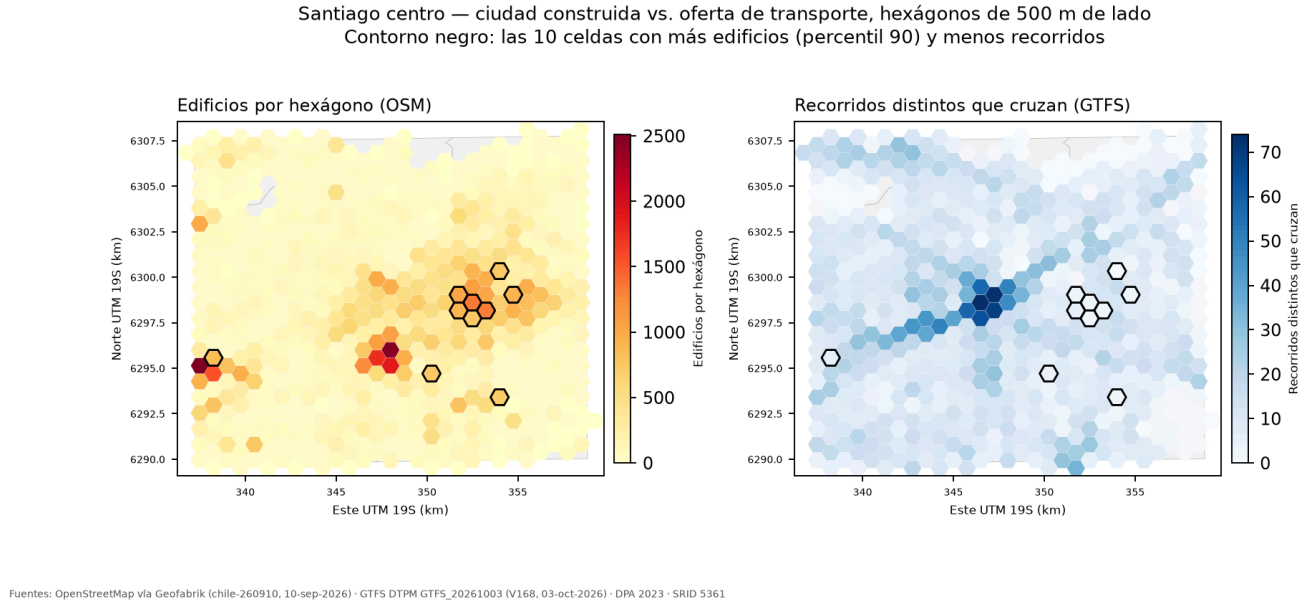
> **Interpretación.** Santiago concentra la red porque es el nodo del sistema, no por su tamaño. `ST_Subdivide` acelera ×2,2 cuando el polígono es grande (12.601 vértices en las comunas enteras) porque cada trozo tiene una caja ajustada y el GIST descarta más falsos positivos; recortar a la caja ya quita esos vértices (5.106) y subdividir después no suma. **Plan:** *Nested Loop* con `idx_recorridos_geom` en el lado de las líneas (`geom && c.geom`, 78 líneas por trozo) y *Seq Scan* sobre `comunas_sub` (34 filas: no necesita índice); el costo está en `ST_Intersection` y el *Sort external merge* de ~14 MB, no en el acceso. Sin `idx_recorridos_geom` sería 34 × 690 comparaciones de geometrías de miles de vértices. *Fuente: GTFS 03-oct-2026.*

2.5 Vecino más cercano: ruta 210 (`CROSS JOIN LATERAL` + `<->` + `LIMIT 1`)

Ruta 210 (Estación Central – Puente Alto), 131 paraderos a ≤ 15 m de su trazado; para cada uno, la farmacia, hospital, clínica o consultorio más cercano (865 farmacias, 268 clínicas, 168 «doctors», 48 hospitales en la caja). **Mediana 91 m, media 154 m, máximo 762 m** (Av. Vicuña Mackenna, Farmacia Amaya); varios paraderos de Plaza Italia / Santa Lucía a < 10 m.

> **Interpretación.** A lo largo de un eje comercial como Vicuña Mackenna casi cualquier paradero tiene un servicio de salud a menos de ~150 m: no es el acceso a salud lo que limita la ruta, sino la frecuencia. **Plan:** `Index Scan using idx_amenidades_geom … Order By: geom <-> paraderos_gtfs.geom, LIMIT 1, Filter: amenity = ANY(…)` (20 filas descartadas por el filtro en cada búsqueda): 22 ms para 200 paraderos, el índice devuelve vecinos en orden de distancia y se detiene al primero que pasa el filtro. Sin índice habría que ordenar las 20.770 amenidades por cada paradero. Poner el filtro *dentro* del LATERAL garantiza que el «más cercano» sea del tipo pedido.

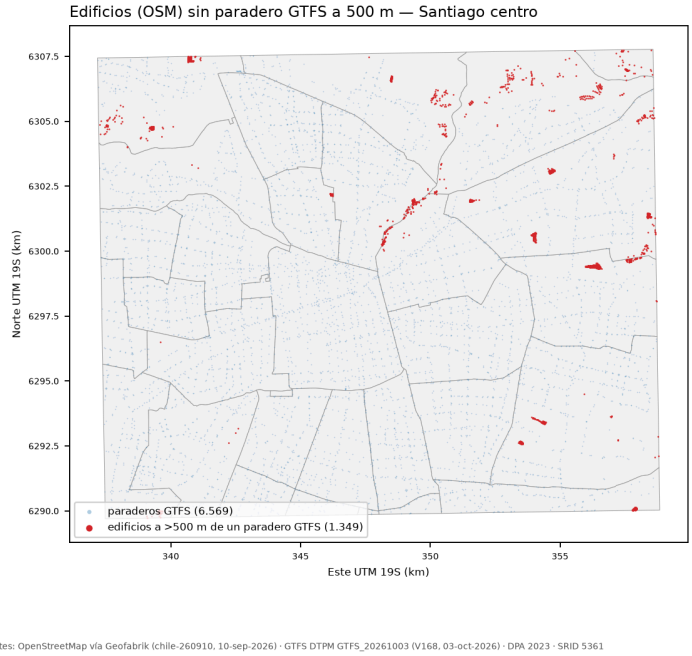
2.6 Grilla hexagonal de 500 m (`ST_HexagonGrid` + vista materializada) — mapa principal



Mapa 1. Edificios y recorridos distintos por hexágono (lado de 500 m, 649.519 m²). Contorno: las 10 celdas con más edificios (percentil 90) y menos recorridos.

682 celdas, 603 con edificios; **34 tienen edificios y ningún recorrido**. Las 10 celdas con más edificios y menos recorridos (0 a 5 recorridos; 700 a 1.340 edificios) están, nueve de diez, en el oriente (lon −70,61… −70,56), la décima en el poniente (lon −70,74).

> **Interpretación.** La oferta se concentra en un eje que cruza la ciudad (derecha del mapa: 40–74 recorridos en el centro) mientras el oriente residencial denso tiene mucha ciudad construida y pocos recorridos. Matiz importante: **esa franja oriente probablemente está servida en parte por Metro (p. ej. líneas 1, 4 y 6)**, que no entra en este análisis; la brecha es de *buses*, no necesariamente de transporte público. *Fuentes: OSM 10-sep-2026; GTFS 03-oct-2026.*



Mapa 3. Edificios a más de 500 m de un paradero GTFS (1.349 de 118.700).

2.7 Pregunta propia: ¿qué oferta de buses tienen hospitales y clínicas?

Cruza OSM (amenidades `hospital` y `clinic`) con GTFS (viajes por día laboral por paradero, ya expandidos por `frequencies.txt`): paraderos y rutas distintas a ≤ 300 m, y viajes por día. No es una variante de Q2: acá el objeto es el establecimiento y la medida es oferta (viajes), no presencia de un paradero.

Tipo	Establec.	Sin paradero a 300 m	Rutas (promedio)	Viajes/día (mediana)
Clínica	268	6	13,7	2.226
Hospital	48	0	13,6	1.889

> **Interpretación.** Todos los hospitales tienen paradero a 300 m, pero la oferta es muy desigual: el de menor servicio (Hospital Instituto Nacional de Geriatría) recibe ~260 viajes/día frente a una mediana de ~1.900; el Hospital de Enfermedades Infecciosas, 150. Seis clínicas no tienen paradero; tres de ellas son CESFAM municipales (Apoquindo, Petrinovic, Rosita Renard), es decir, atención primaria. «Viajes por día» suma el paso por todos los paraderos del radio: es un indicador de oferta, no de personas. *Fuentes: OSM 10-sep-2026; GTFS 03-oct-2026.*

3. Decisiones del pipeline

SRID 5361 (SIRGAS-Chile / UTM 19S) en todo: metros para distancias, largos, áreas y la grilla. OSM se reproyecta al recortar (`ogr2ogr -t_srs`); los puntos del GTFS (4326) se transforman con `ST_Transform`.

Punto interior vs. polígono. Para distancias, el edificio se representa con `ST_PointOnSurface` (siempre cae dentro; el centroide puede caer fuera de un polígono cóncavo) y el índice sobre puntos filtra mucho mejor que sobre polígonos; el polígono se conserva para áreas. Costo: un edificio grande se mide desde un solo punto.

Reparaciones (`ST_MakeValid`). 368 de 146.619 polígonos OSM eran inválidos (0,25 %; 8,9 km² declarados): *Too few points* 232, *Invalid number of points in LinearRing* 77, *Self-intersection* 58, *Ring self-intersection* 1. Tras `ST_MakeValid + ST_CollectionExtract(…,3)` quedan 0 inválidos, pero **309 quedaron vacíos** (anillos de menos de 4 puntos, irreparables) y se excluyen. Una línea inválida no se tocó.

Shapes múltiples por ruta. Una `LineString` por `shape_id` (`ST_MakeLine(punto ORDER BY shape_pt_sequence)`, con la secuencia como entero). Cada ruta tiene varios shapes (ida, vuelta, variantes): se marcó *canónico* el de más viajes por (ruta, sentido) — 586 de 690 — y se usa para medir km de red; las preguntas que cuentan rutas usan todos los shapes con `DISTINCT route_id`. Contar todas las variantes infla los km hasta un 45 % según la comuna.

Solo buses. El feed trae Metro (`route_type` 1) y trenes EFE; sus andenes se mezclaban con los paraderos y falseaban Q3 (453 vs. 381 GTFS «sin OSM» a 50 m). Se excluyen 9 rutas y 243 stops de la caja; también estaciones, accesos y nodos (`location_type` 1–4). Los trips con `frequencies.txt` se expanden por headway antes de contar viajes.

Comunas recortadas a la caja para la densidad y las áreas; `ST_Subdivide` a 256 vértices para los joins pesados (34 trozos).

Índices creados y cuál resultó inútil. GIST en todas las tablas con geometría, btree en `cut_com`, `amenity`, `route_short_name`; `ANALYZE` al final. Con `pg_stat_user_indexes`: los de `paraderos_gtfs` (383.070 lecturas) y `paraderos_osm` (263.676) son el corazón del pipeline. **Inútil:** `idx_edificios_geom` **(9,8 MB, 0 lecturas)**: todas las consultas usan el punto interior (`idx_edificios_punto`, 716 lecturas). También sin lecturas: `idx_calles_geom` (4,2 MB; ninguna pregunta consulta `calles`) y los de las tablas de 30–34 filas (el planificador prefiere *Seq Scan* del lado exterior). Es un hallazgo del diseño, no un error.

Honestidad con el dato. Los `bus_stop` de OSM son los que alguien dibujó (81 de 6.567 sin nombre); el GTFS es lo que el operador declara y vale a su fecha (V168, 03-oct-2026). Distancias en línea recta, no peatonales. OSM puede estar incompleto en la periferia (cobertura aparentemente mejor). La oferta de viajes considera el día laboral y no los feriados. El Metro está fuera: toda conclusión sobre «cobertura» o «oferta» es de buses, con OSM del 10-sep-2026 y GTFS del 03-oct-2026.